

Анализ брака на производстве медных проводов

Навротский Никита

Задача

Проанализировать данные с производства медных проводов.

Цель

Понять причины брака и простоя на линии производства.

Данные

Информация с линии производства



Инструменты

- Python
- Jupyter Notebook
- Power BI
- Github



Power BI



pythonTM

Первоначальные данные

149 записей, 8 признаков: Machine, Shift, Operator, Date, Cable Failures, Cable Failure Downtime, Other Failures, Other Failure Downtime).

```
data.head()
```

	Machine	Shift	Operator	Date	Cable Failures	Cable Failure Downtime	Other Failures	Other Failure Downtime
0	1	A	1	11/6/2020	1	35	1	30
1	2	A	2	11/6/2020	1	10	3	150
2	2	B	3	11/6/2020	2	40	2	110
3	2	A	2	11/7/2020	5	120	1	80
4	2	B	3	11/7/2020	2	40	1	35

Преобразованные данные (Предобработка и признаков)

149 записей, 8 признаков: Machine, Shift, Operator,
Date (A-0, B-1), Cable Failures, Cable Failure
Downtime, Other Failures, Other Failure Downtime,
Total Failures, Total Downtime).

```
data.head()
```

	Machine	Shift	Operator	Date	Cable Failures	Cable Failure Downtime	Other Failures	Other Failure Downtime	Total Failures	Total Downtime
0	1	0	1	2020-11-06	1	35	1	30	2	65
1	2	0	2	2020-11-06	1	10	3	150	4	160
2	2	1	3	2020-11-06	2	40	2	110	4	150
3	2	0	2	2020-11-07	5	120	1	80	6	200
4	2	1	3	2020-11-07	2	40	1	35	3	75

Исследовательский анализа (EDA)

data.describe()										
	Machine	Shift	Operator	Date	Cable Failures	Cable Failure Downtime	Other Failures	Other Failure Downtime	Total Failures	Total Downtime
count	149.000000	149.000000	149.000000		149	149.000000		149.000000	149.000000	149.000000
mean	5.932886	0.489933	12.946309	2020-11-15 12:14:29.798657792	1.409396	51.442953	0.536913	47.04698	1.946309	98.489933
min	1.000000	0.000000	1.000000	2020-11-06 00:00:00	0.000000	0.000000	0.000000	0.00000	0.000000	0.000000
25%	2.000000	0.000000	6.000000	2020-11-12 00:00:00	0.000000	0.000000	0.000000	0.00000	1.000000	30.000000
50%	5.000000	0.000000	12.000000	2020-11-15 00:00:00	1.000000	35.000000	0.000000	0.00000	1.000000	60.000000
75%	8.000000	1.000000	18.000000	2020-11-19 00:00:00	2.000000	70.000000	1.000000	45.00000	2.000000	120.000000
max	17.000000	1.000000	32.000000	2020-11-22 00:00:00	6.000000	295.000000	9.000000	690.00000	9.000000	690.000000
std	4.294346	0.501585	8.659306		NaN	1.325495	0.969281	106.39678	1.417960	112.009750

Исследовательский анализа (EDA)

```
data['Operator'].unique()
```

```
array([ 1,  2,  3,  4,  5,  6,  7,  9,  8, 14, 26, 15, 13, 11, 10, 12, 18,  
       17, 16, 27, 20, 19, 22, 21, 28, 23, 24, 25, 29, 31, 30, 32])
```

```
data['Machine'].unique()
```

```
array([ 1,  2,  3,  5,  4,  7, 14,  8, 15,  6,  9, 13, 16, 11, 10, 12, 17])
```

```
data['Shift'].unique()
```

```
array([0, 1])
```

Исследовательский анализа (EDA)

```
data['Cable Failures'].sum()
```

```
np.int64(210)
```

```
data['Cable Failure Downtime'].sum()
```

```
np.int64(7665)
```


```
data['Other Failures'].sum()
```

```
np.int64(80)
```


```
data['Other Failure Downtime'].sum()
```

```
np.int64(7010)
```



Исследовательский анализа (EDA)




Исследовательский анализа (EDA)




Исследовательский анализа (EDA)



Исследовательский анализа (EDA)




Исследовательский анализа (EDA)




Исследовательский анализа (EDA)

Cable Failures by Machine




Cable Failure Downtime by Machine




Исследовательский анализа (EDA)


Cable Failures by Operator




Cable Failure Downtime by Operator



Исследовательский анализа (EDA)



Исследовательский анализа (EDA)



Статистический анализ и кластеризация

```
from sklearn.cluster import KMeans
from sklearn.preprocessing import StandardScaler
machine_features = data.groupby('Operator')[['Cable Failures', 'Cable Failure Downtime', 'Other Failures', 'Other Failure Downtime',
                                             'Total Failures', 'Total Downtime']].sum()

scaled = StandardScaler().fit_transform(machine_features)

kmeans = KMeans(n_clusters=3, random_state=101, n_init=35)
machine_features['Cluster'] = kmeans.fit_predict(scaled)

machine_features.groupby('Cluster').sum()
```

	Cable Failures	Cable Failure Downtime	Other Failures	Other Failure Downtime	Total Failures	Total Downtime
Cluster						
0	16	495	33	1615	49	2110
1	107	3870	28	4125	135	7995
2	87	3300	19	1270	106	4570

```
machine_features[machine_features['Cluster']==1].index
```

```
Index([1, 3, 6, 7, 13, 14, 31], dtype='int64', name='Operator')
```

Статистический анализ и кластеризация

```
machine_features = data.groupby('Machine')[['Cable Failures', 'Cable Failure Downtime', 'Other Failures', 'Other Failure Downtime', 'Total Failures', 'Total Downtime']].sum()
```

```
scaled = StandardScaler().fit_transform(machine_features)
```

```
kmeans = KMeans(n_clusters=3, random_state=101, n_init=20)
machine_features['Cluster'] = kmeans.fit_predict(scaled)
```

```
machine_features.groupby('Cluster').sum()
```

	Cable Failures	Cable Failure Downtime	Other Failures	Other Failure Downtime	Total Failures	Total Downtime
Cluster						
0	41	1230	32	1965	73	3195
1	95	2980	25	4095	120	7075
2	74	3455	23	950	97	4405

```
machine_features[machine_features['Cluster']==1].index
```

```
Index([2, 8], dtype='int64', name='Machine')
```

Статистический анализ и кластеризация

Нулевая Гипотеза

H0 -- Пропорция брака по сменам одинаковая.

H1 -- Пропорция брака по сменам не одинаковая. Другими словами, смена влияет на частоту брака.

```
from scipy.stats import mannwhitneyu
```

```
shift0_failures = data[data['Shift']==0]['Cable Failures']  
shift1_failures = data[data['Shift']==1]['Cable Failures']
```

```
u, p_value = mannwhitneyu(shift0_failures, shift1_failures, alternative='two-sided')  
print('P value: ', p_value)
```

```
if p_value < 0.05:  
    print('Смена влияет на количество брака. Отвергаем H0.')  
else:  
    print('Смена НЕ влияет на количество брака. Не можем отвергать H0.')
```

P value: 0.355659591401393

Смена НЕ влияет на количество брака. Не можем отвергать H0.

```
shift0_failures = data[data['Shift']==0]['Other Failures']  
shift1_failures = data[data['Shift']==1]['Other Failures']
```

```
u, p_value = mannwhitneyu(shift0_failures, shift1_failures, alternative='two-sided')  
print('P value: ', p_value)
```

```
if p_value < 0.05:  
    print('Смена влияет на количество брака. Отвергаем H0.')  
else:  
    print('Смена НЕ влияет на количество брака. Не можем отвергать H0.')
```

P value: 0.9737314963206812

Смена НЕ влияет на количество брака. Не можем отвергать H0.

Статистический анализ и кластеризация

Нулевая Гипотеза

H0 -- Пропорция времени простоя по сменам одинаковая.

H1 -- Пропорция времени простоя по сменам не одинаковая. Другими словами, смена влияет на количество времени простоя.

```
shift0_failures = data[data['Shift']==0]['Cable Failure Downtime']
shift1_failures = data[data['Shift']==1]['Cable Failure Downtime']

u, p_value = mannwhitneyu(shift0_failures, shift1_failures, alternative='two-sided')
print('P value: ', p_value)

if p_value < 0.05:
    print('Смена влияет на количество брака. Отвергаем H0.')
else:
    print('Смена НЕ влияет на количество брака. Не можем отвергнуть H0.')
```

P value: 0.749982079103189

Смена НЕ влияет на количество брака. Не можем отвергнуть H0.

```
shift0_failures = data[data['Shift']==0]['Other Failure Downtime']
shift1_failures = data[data['Shift']==1]['Other Failure Downtime']

u, p_value = mannwhitneyu(shift0_failures, shift1_failures, alternative='two-sided')
print('P value: ', p_value)

if p_value < 0.05:
    print('Смена влияет на количество брака. Отвергаем H0.')
else:
    print('Смена НЕ влияет на количество брака. Не можем отвергнуть H0.')
```

P value: 0.9434185746695916

Смена НЕ влияет на количество брака. Не можем отвергнуть H0.

Выводы

- Наиболее проблемные и рисковые машины: 2, 8.
 - Наиболее проблемные операторы: 1, 3, 6, 7, 13, 14, 31.
 - Самые проблематичные комбинации Машина и Оператор по количеству поломок: 2 и 3, 2 и 7, 7 и 14.
 - Самые проблематичные комбинации Машина и Оператор по количеству времени простоя: 7 и 14, 8 и 15, 8 и 31, 1 и 1.
 - В смене А на 33% больше отказов и на 18% больше простоев, чем в смене В, однако статистически значимой связи не обнаружено ($p > 0.05$).
-

Рекомендации

- Проверить, работали ли высокорисковые операторы на проблемных машинах.
 - Пристально наблюдать за проблемными парами машин и операторов.
 - Рассмотреть корректировку распределения персонала по сменам или дополнительное обучение.
-